



LLM-Serving-Service

Leistungsbeschreibung & zusätzliche
Bedingungen

von T-Systems International GmbH

Version: 1.23

Date: 31. 8. 2026

T Systems

Let's power
higher performance

Impressum

Herausgeber

T-Systems International GmbH

Friedrich-Ebert-Allee 140

53113 Bonn

Deutschland

WEEE-Reg.-Nr. DE50335567

nachfolgend – Telekom - genannt

Die gesetzlichen Pflichtangaben finden Sie unter: www.t-systems.de/pflichtangaben |

Copyright © 2024 Alle Rechte, auch die des auszugsweisen Nachdruckes, der elektronischen oder fotomechanischen Kopie sowie die Auswertung mittels Verfahren der elektronischen Datenverarbeitung, vorbehalten.

Internal PIMS-ID: 34011758/1096

Confidentially Class: Public

Inhaltsverzeichnis

1	Einleitung	4
2	Funktionen	4
2.1	LLM-Self-Service Portal.....	4
2.2	API.....	4
2.3	Verfügbare LLMs und Embedding-Modelle	4
2.3.1	LLMs und Embedding-Modelle mit Datenverarbeitung innerhalb EU/EWR und Staaten mit Angemessenheitsbeschluss.....	5
2.3.2	LLMs und Embedding-Modelle mit Datenverarbeitung außerhalb EU/EWR und Staaten ohne Angemessenheitsbeschluss	6
2.3.3	Testmodelle.....	8
2.4	Chat-Frontend (T-Systems LLM Playground).....	9
3	Leistungen der Telekom	9
3.1	Bereitstellung	9
3.2	Betrieb	9
3.2.1	Kundensupport	9
3.2.2	Leistungsübergabepunkt	10
3.2.3	Service Quality	10
3.2.4	Wartungsarbeiten	11
3.2.5	Reporting	11
3.3	Nutzungsbedingungen, Lizenzbestimmungen	12
3.3.1	Einhaltung der KI-Verordnung.....	12
3.3.2	Allgemeine Nutzungsbedingungen	12
3.3.3	Lizenzen, Nutzungsbedingungen und Datenschutzbestimmungen.....	13
3.3.4	Medical Device Regulation (MDR).....	14
3.3.5	Hochrisiko-KI-Systeme, Verbotene Anwendungsfälle	15
3.3.6	Haftung, Freistellung, Kündigung	15
3.3.7	Feedback.....	15
3.4	Optionale Leistungen.....	15
3.4.1	LLMs auf dedizierter Instanz	16
3.4.2	Feintuning von Modellen	16
3.4.3	Installation auf einer kundeneigenen Umgebung	16
3.4.4	Zusätzliche LLMs und Embedding Modelle	16
3.4.5	Weitere Unterstützungsleistungen	16

4	Leistungsänderungen durch Telekom.....	16
5	Mitwirkungsleistungen des Kunden	17
5.1	Allgemeine Mitwirkungsleistungen	17
5.2	Mitwirkungsleistungen bei Betrieb.....	18
6	Mindestlaufzeit/Beendigung	19
7	Preise, Kommerzielle Bedingungen.....	19
7.1	Verfahren der Entgeltberechnung	19
7.2	Preise	20
7.2.1	Tarif Essential	20
7.2.2	Tarif Professional.....	21
7.2.3	Tarif Agentic	23
7.2.4	Preise für optionale Dienstleistungen	25
8	Glossar/ Abkürzungsverzeichnis	25

1 Einleitung

Mit dem LLM-Serving-Service stellt die Telekom dem Kunden einen Zugang zu verschiedenen Large Language Modellen (LLM) und Embedding-Modellen as-a-Service zur Nutzung im Self-Service bereit. Der Zugang zu den LLMs und Embedding-Modellen wird über eine API mittels eines API-Keys bereitgestellt. Mit diesem hat der Kunde die Möglichkeit, die LLMs über ein Chat-Frontend zu nutzen.

2 Funktionen

2.1 LLM-Self-Service Portal

Das Self-Service Portal ist durch den Kunden über das Internet unter <https://apikey.llmhub.t-systems.net> erreichbar und bietet diesem folgende Funktionen zur Nutzung im Self-Service:

- a. Übersicht der verfügbaren API-Keys und der mit den Keys verbundenen Modellen.
- b. Generierung und Verwaltung von API-Keys für den Zugang zu den Modellen.
- c. Übersicht des Token-Verbrauchs je Key und Modell.

Die Telekom stellt dem Kunden-Administrator Log-In-Daten für das LLM-Self-Service Portal bereit. Der Kunden-Administrator kann für das Portal weitere Nutzer anlegen, die sich dort im Self-Service einen oder mehrere API-Keys generieren können. Die generierten API-Keys ermöglichen den Zugriff auf die Modelle des vereinbarten Tarifs.

2.2 API

Der Kunde kann die ausgewählten LLMs und Embedding-Modelle über eine standardisierte API ansteuern. Dies ist via HTTPS-Request oder mit Hilfe des Python Pakets „openai“ möglich. Die Telekom stellt dem Kunden eine aktuelle Dokumentation unter <https://docs.llmhub.t-systems.net/category/model-serving> zur Verfügung.

2.3 Verfügbare LLMs und Embedding-Modelle

Der LLM-Serving-Service unterliegt einer ständigen Weiterentwicklung. Die verfügbaren LLMs und Embedding-Modelle können sich daher von Zeit zu Zeit ändern, Modelle können von der Telekom hinzugefügt und entfernt werden.

Der LLM-Serving-Service stellt 2 Gruppen von LLMs und Embedding Modellen bereit:

- LLMs und Embedding-Modelle, bei denen die Datenverarbeitung nur innerhalb EU/EWR und in Staaten mit einem datenschutzrechtlichen Angemessenheitsbeschluss der EU-Kommission stattfindet.

- LLMs und Embedding-Modelle, bei denen die Datenverarbeitung auch außerhalb der EU/EWR und/oder in Staaten ohne datenschutzrechtlichen Angemessenheitsbeschluss der EU-Kommission stattfindet.

Die Telekom weist ausdrücklich darauf hin, dass es aufgrund gesetzlicher Bestimmungen (wie bspw. im Bereich der Verarbeitung von Sozialdaten und/-oder Gesundheitsdaten) unzulässig ist, bestimmte Datenkategorien außerhalb der EU/EWR und in Ländern ohne datenschutzrechtlichen Angemessenheitsbeschluss der EU -Kommission zu verarbeiten. Bei dieser Betrachtung sind auch die Unterauftragnehmer jeden Grades über die Verarbeitungskette in die rechtliche Bewertung mit einzubeziehen (z.B. § 80 Abs. 2 SGB X, § 393 Abs. 2 SGB V).

Die Telekom weist ferner darauf hin, dass die rechtliche Bewertung der Zulässigkeit der Nutzung einer der in dieser Leistungsbeschreibung beschriebenen LLMs und Embedding-Modelle allein in den Verantwortungsbereich des Kunden fällt und die Telekom die Zulässigkeit der Nutzung der ausgewählten LLMs und Embedding-Modelle durch den Kunden nicht überprüfen kann und wird.

Aus diesem Grunde sichert der Kunde der Telekom zu, dass er die Zulässigkeit der Nutzung der ausgewählten LLMs und Embedding-Modelle geprüft hat und hierfür die alleinige Verantwortlichkeit trägt. Ansprüche, die aus einer rechtswidrigen Nutzung der LLMs und Embedding-Modelle resultieren, sind vom Kunden allein zu tragen und berechtigen nicht zu Haftungsansprüchen, Regressforderungen und der Ausübung vertraglicher Gestaltungsrechte gegenüber der Telekom. Der Kunde stellt die Telekom von allen Ansprüchen von Betroffenen und Dritten (insb. Aufsichtsbehörden) - auf erstes Anfordern - vollumfänglich frei und erstattet der Telekom die Kosten der notwendigen Rechtsverteidigung, soweit diese auf einer rechtswidrigen Nutzung der Leistung beruhen. Weitergehende Schadenersatzansprüche infolge gesetzeswidriger Nutzung bleiben unberührt.

2.3.1 LLMs und Embedding-Modelle mit Datenverarbeitung innerhalb EU/EWR und Staaten mit Angemessenheitsbeschluss

Die LLMs und Embedding-Modelle dieser Kategorie werden von der Telekom betrieben. Die Verarbeitung der Daten und die Leistungserbringung erfolgt innerhalb der EU/EWR und/oder in Staaten mit datenschutzrechtlichem Angemessenheitsbeschluss der EU-Kommission.

Ihre Anfragen und die darauf erhaltenen Antworten werden im LLM Serving Service standardmäßig nicht dauerhaft gespeichert und auch nicht dazu verwendet, die Sprachmodelle zu trainieren. Damit der Service schneller antwortet, gibt es eine sogenannte Cache-Funktion: Dabei werden bereits verarbeitete Anfragen für eine begrenzte Zeit zwischengespeichert, sodass ähnliche oder wiederkehrende Anfragen schneller beantwortet werden können. Diese Funktion ist standardmäßig eingeschaltet, kann von Kunden aber jederzeit ein- oder ausgeschaltet werden.

Weitere Informationen zu den Cache-Einstellungen: <https://docs.llmhub.t-systems.net/guides/prefix-caching/>

Aktuell sind folgende Modelle verfügbar:

Modell	Modelltyp	Plattform
Gemma 4 31B	LLM	T-Cloud Public
Mistral AI Mistral Small 4	LLM	T-Cloud Public
Qwen3.6 35B	LLM	T-Cloud Public
Qwen 3.8 27B	LLM	T-Cloud Public
NVIDIA Nemotron 3 Super	LLM	T-Cloud Public
GLM 5.2	LLM	T-Cloud Public / Industrial AI Cloud
GLM 5.3 Flash	LLM	T-Cloud Public / Industrial AI Cloud
Jina AI jina-embeddings-v2-base-de	Embedding	T-Cloud Public
BAAI text-embedding-bge-m3	Embedding	T-Cloud Public
OpenAI GPT-OSS-120B	LLM	T-Cloud Public
OpenAI Whisper Large v3	STT	T-Cloud Public
OpenAI Whisper Large v3 Turbo	STT	T-Cloud Public

2.3.2 LLMs und Embedding-Modelle mit Datenverarbeitung außerhalb EU/EWR und Staaten ohne Angemessenheitsbeschluss

Die LLMs und Embedding-Modelle dieser Kategorie werden nicht von der Telekom betrieben. Die Verarbeitung der Daten und die Leistungserbringung kann außerhalb der EU/EWR und/oder in Staaten ohne datenschutzrechtlichem Angemessenheitsbeschluss der EU-Kommission erfolgen.

Anfragen an LLMs und Embedding Modelle dieser Kategorie werden über die LLM-Serving Schnittstelle der Telekom direkt an den jeweiligen Drittanbieter weitergeleitet, der diese auf eigenen Infrastrukturen betreibt.

Mit der Auswahl/Nutzung dieser Modelle akzeptiert der Kunde die Nutzungsbedingungen und Lizenzbestimmungen, insbesondere die Datenschutzbestimmungen, des jeweiligen Drittanbieters.

Der Drittanbieter kann Subunternehmer weltweit einsetzen, so dass die Daten des Kunden weltweit verarbeitet werden.

Aktuell sind folgende Modelle dieser Kategorie verfügbar:

Modell	Modelltyp	Plattform
OpenAI GPT-5 Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-5 mini Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-5 nano Azure Sweden	LLM	Microsoft Azure

Modell	Modelltyp	Plattform
OpenAI GPT-5 Codex Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-5.4 Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-5.4 mini Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-5.5 Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-5.6 Sol Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-5.6 Terra Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-5.6 Luna Azure Sweden	LLM	Microsoft Azure
OpenAI GPT-Image-2	LLM	Microsoft Azure
OpenAI Ada-Text, Azure France	Embedding	Microsoft Azure
Mistral AI Mistral Medium 3	LLM	Google Cloud Platform
Anthropic Claude 4.5 Haiku	LLM	Google Cloud Platform & Microsoft Azure
Anthropic Claude 4.6 Sonnet	LLM	Google Cloud Platform & Microsoft Azure
Anthropic Claude 4.6 Opus	LLM	Google Cloud Platform & Microsoft Azure
Anthropic Claude 4.8 Opus	LLM	Google Cloud Platform & Microsoft Azure
Anthropic Claude Opus 5	LLM	Google Cloud Platform & Microsoft Azure
Anthropic Claude Sonnet 5	LLM	Google Cloud Platform & Microsoft Azure
Anthropic Claude Fable 5	LLM	Google Cloud Platform & Microsoft Azure
Google Gemini 3 Flash	LLM	Google Cloud Platform
Google Gemini 3 Pro	LLM	Google Cloud Platform
Google Gemini 3.1 Pro	LLM	Google Cloud Platform
Google Gemini 3.5 Flash	LLM	Google Cloud Platform

Modell	Modelltyp	Plattform
Google Gemini 3 Pro Image	LLM	Google Cloud Platform

2.3.3 Testmodelle

Neben den produktiv nutzbaren Modellen stellt die Telekom dem Kunden weitere Large Language Models und Embedding-Modelle als Evaluierungsmodelle über die API unentgeltlich zur Verfügung. Die Evaluierungsmodelle dienen ausschließlich der technischen Erprobung und funktionalen Bewertung durch den Kunden; sie sind nicht für den produktiven Einsatz bestimmt.

Die Datenverarbeitung erfolgt ausschließlich innerhalb der EU/des EWR bzw. in Staaten mit einem geltenden Angemessenheitsbeschluss der Europäischen Kommission.

Die Nutzung der Evaluierungsmodelle ist unentgeltlich. Die Telekom ist berechtigt, den Nutzungsumfang jederzeit zu limitieren, insbesondere hinsichtlich des verfügbaren Token-Kontingents, der Rate-Limits (TPM/RPM) sowie der Nutzungsdauer.

Aktuell sind folgende Testmodelle verfügbar:

<https://docs.llmhub.t-systems.net/plans/test>

Die jeweils verfügbaren Evaluierungsmodelle werden im Self-Service-Portal des LLM-Serving-Service ausgewiesen und durch die Telekom fortlaufend aktualisiert. Ein Rechtsanspruch auf die Bereitstellung bestimmter oder sämtlicher dort aufgeführter Modelle besteht nicht. Für Evaluierungsmodelle wird keine Mindestverfügbarkeit zugesagt. Die Telekom ist jedoch bestrebt, Leistungseinschränkungen im Rahmen ihrer technischen und betrieblichen Möglichkeiten gering zu halten.

Nutzungsbedingungen und Einschränkungen

Die Evaluierungsmodelle sind nicht für den Einsatz im Wirkbetrieb und nicht für die Verarbeitung von Echtdaten konzipiert. Setzt der Kunde die Evaluierungsmodelle gleichwohl im Wirkbetrieb oder mit Echtdaten ein, erfolgt dies in alleiniger Verantwortung des Kunden; eine Haftung der Telekom für hieraus resultierende Schäden ist – soweit gesetzlich zulässig – ausgeschlossen.

Die Telekom ist jederzeit und ohne Angabe von Gründen berechtigt, einzelne oder sämtliche Evaluierungsmodelle einzustellen, zu ändern oder den Zugang des Kunden ganz oder teilweise zu beschränken. Der Kunde hat keinen Rechtsanspruch auf die fortlaufende oder unveränderte Bereitstellung der Evaluierungsmodelle.

Da es sich um einen Evaluierungsbetrieb handelt, muss mit eingeschränkter Leistungsfähigkeit gerechnet werden. Die Telekom ist bestrebt, etwaige Leistungsstörungen im Rahmen ihrer technischen und betrieblichen Möglichkeiten zeitnah zu beheben und den Evaluierungsbetrieb fortlaufend zu optimieren.

2.4 Chat-Frontend (T-Systems LLM Playground)

Mit dem im LLM-Self-Service-Portal generierten API-Key erhält der jeweilige Nutzer des Kunden Zugang zum Chat-Frontend T-Systems LLM Playground für den Dialog mit den LLMs des vereinbarten Tarifs. Das Tool speichert oder persistiert keine Chat-Daten, alle Interaktionen werden in Echtzeit verarbeitet. Der T-Systems LLM Playground ist unter der URL <https://public.oweb-chat.llmhub.t-systems.net> über eine https-gesicherte Verbindung über das Internet erreichbar.

3 Leistungen der Telekom

3.1 Bereitstellung

Die Telekom richtet den LLM-Serving-Service gemäß Beauftragung ein und versendet die Zugangsdaten nebst URL für das LLM-Self-Service-Portal sowie den relevanten Kontakt-E-Mail-Adressen per E-Mail an den Kunden.

Die Bereitstellung ist mit Versendung der E-Mail, spätestens mit Nutzungsbeginn durch den Kunden abgeschlossen.

3.2 Betrieb

3.2.1 Kundensupport

Der Kundensupport der Telekom ist der zentrale Ansprechpartner für die benannten Administratoren des Kunden als 2nd-Level-Support und erbringt folgende Leistungen:

- a. Bearbeitung von Incidents
- b. Beantwortung von Service-Requests

Der Kundensupport ist unter der dem Kunden im Rahmen der Bereitstellung mitgeteilten E-Mail-Adresse erreichbar während der betreuten Betriebszeit (Montag bis Freitag von 9:00 Uhr bis 17.00 Uhr MEZ/MESZ, ausgenommen an bundeseinheitlichen Feiertagen in Deutschland) erreichbar.

Anfragen des Kunden bearbeitet die Telekom nach folgendem Prozess:

- a. Die Telekom eröffnet ein Ticket, versendet per E-Mail eine Eingangsbestätigung der Anfrage nebst Ticketnummer.
- b. Die Telekom analysiert die Anfrage des Kunden und setzt sich soweit erforderlich zwecks Klärung von Fragen mit diesem in Verbindung.
- c. Die Telekom informiert den Kunden per E-Mail über den Status und den Abschluss der Bearbeitung.

Für die Bearbeitung von Tickets gilt:

- a. Tickets werden ausschließlich innerhalb der betreuten Betriebszeit bearbeitet.

- b. Für die Bearbeitung von Incidents gelten keine zugesagten Lösungszeiten.
- c. Die Telekom ist berechtigt, Incidents durch die Bereitstellung eines Workarounds zu beheben.

3.2.2 Leistungsübergabepunkt

Die Verantwortung der Telekom endet am Leistungsübergabepunkt. Der Leistungsübergabepunkt ist der API Endpoint des LLM-Serving-Services im Rechenzentrum der Telekom.

3.2.3 Service Quality

a. Mindestverfügbarkeit

Die Mindestverfügbarkeit des LLM-Serving-Services am Leistungsübergabepunkt für Tarife mit Mindestumsatz liegt bei 99,5% innerhalb der betreuten Betriebszeit eines Kalendermonats und wird wie folgt berechnet:

$$\left[\left(\frac{\text{Gesamte Serviceminuten} - \text{Gesamte Ausfallminuten}}{\text{Gesamte Serviceminuten}} \right) * 100 \right]$$

Die Mindestverfügbarkeit wird als Prozentsatz ausgewiesen. Dabei bedeutet:

Gesamte Serviceminuten – die gesamte Anzahl der Minuten während der betreuten Betriebszeit innerhalb eines Kalendermonats.

Gesamte Ausfallminuten – die Anzahl der Minuten innerhalb der betreuten Betriebszeit innerhalb eines Kalendermonats, in der der LLM-Serving-Service nicht verfügbar ist abzüglich der ausgeschlossenen Ereignisse (Excused Events) in Minuten.

Im Übrigen gilt keine Mindestverfügbarkeit. Die Telekom ist jedoch bemüht, Leistungseinschränkungen zu vermeiden.

b. Excused Events (Ausgeschlossene Ereignisse/Suspend-Zeiten)

Unterbrechungen der Leistung, die auf einem den nachfolgenden Ereignissen basieren, gelten nicht als Ausfallminuten:

- i. Ausfälle, die durch Wartungsarbeiten verursacht werden;
- ii. Störungen, Ausfälle und Probleme die auf den Kunden, seine Mitarbeiter oder sonst dem Kunden zuzurechnender Dritter zurückzuführen sind.
- iii. Ausfälle, die auf eine Einwirkung von Dritten oder höhere Gewalt zurückzuführen sind.
- iv. Störungen, Ausfälle und Probleme, die auf Leistungen von Drittanbietern, insbesondere im Zusammenhang der Bereitstellung von LLMs mit Betrieb außerhalb EU zurückzuführen sind.

c. Service Credits

Bei Nichteinhaltung der Mindestverfügbarkeit erstattet die Telekom dem Kunden nachfolgende Service Credits unter folgenden Voraussetzungen:

- i. Die Telekom hat die Nichteinhaltung der vereinbarten Verfügbarkeit im jeweiligen Abrechnungszeitraum ausschließlich zu vertreten.
- ii. Die Service Credits werden durch den Kunden via E-Mail an die im Rahmen der Bereitstellung zur Verfügung gestellte Emailadresse innerhalb einer Frist von drei Monaten ab dem Abrechnungszeitraum geltend gemacht.
- iii. Die Höhe der Gutschrift des jeweiligen Abrechnungszeitraums beträgt mindestens 1,00 EUR.
- iv. Die Telekom prüft den Anspruch des Kunden und teilt diesem im Falle eines positiven Prüfungsergebnisses die Höhe der Erstattung mit.
- v. Die Telekom verrechnet die Service Credits mit der auf die Bestätigung folgenden Monatsrechnung, bzw. überweist diese nach Beendigung der Leistung an die kundenseitig benannte Bankverbindung.

Die Höhe der Service Credits wird abhängig von dem vom Kunden für den jeweiligen Abrechnungszeitraum tatsächlich gezahlten Mindestumsatzes wie folgt berechnet:

Verfügbarkeit im jeweiligen Abrechnungszeitraum	Höhe der Servicecredits für die betroffene Leistung
<99,5% - 99,3%	5% des vereinbarten Mindestumsatzes
<99,3 – 95%	10% des vereinbarten Mindestumsatzes
<95%	25% des vereinbarten Mindestumsatzes

Gewährte Service Credits werden auf etwaige Schadensersatzansprüche und sonstige Ansprüche auf Grund der Nichteinhaltung der Verfügbarkeit des Kunden angerechnet. Diese Regelung ist abschließend.

3.2.4 Wartungsarbeiten

Die Telekom führt regelmäßig Wartungsarbeiten durch. Sollten diese Wartungsarbeiten zu Unterbrechungen der Leistung führen, wird die Telekom den Kunden vorab informieren. Die Telekom ist hierbei bestrebt, Beeinträchtigungen durch Wartungsarbeiten möglichst gering zu halten. Wartungsarbeiten gelten nicht als Ausfallzeiten und bleiben daher bei der Berechnung der Verfügbarkeit unberücksichtigt.

3.2.5 Reporting

Die Telekom stellt dem Kunden in den Tarifen mit Mindestumsatz auf Anfrage ein monatliches Reporting mit folgendem Inhalt bereit:

Verfügbarkeit (Übersicht)	Einhaltung der Mindestverfügbarkeit
Verfügbarkeit (Details)	Umfasst die monatlichen Details zur Verfügbarkeit des API-Endpoints, sowie eine 6-monatige Historie zur Auskunft über Ausfallhäufigkeiten und -zeiten. Des Weiteren werden die Bereitschafts- und Ausfallzeiten des aktuellen Monats sowohl in grafischer als auch tabellarischer Form dargestellt.
Ausfallzeit in Minuten	Protokoll aller Ausfallzeiten innerhalb der betreuten Betriebszeit für den aktuellen Monat.
Legende	Erklärungen zu den einzelnen Bestandteilen des Reports.
Änderungshistorie	Versionsbeschreibung

Der Report wird dem Kunden auf Anfrage fünf Werktage nach Ablauf eines Kalendermonats per E-Mail zugesandt.

3.3 Nutzungsbedingungen, Lizenzbestimmungen

3.3.1 Einhaltung der KI-Verordnung

Die Telekom verpflichtet sich, die im Rahmen dieses Vertrages für den Kunden erbrachten Leistungen, soweit diese den Anwendungsbereich der Verordnung (EU) 2024/1689 über Künstliche Intelligenz (KI-Verordnung) betreffen, im Einklang mit den jeweils auf die Telekom anwendbaren Pflichten der KI-Verordnung zu erbringen. Weitergehende Verpflichtungen oder Garantien werden nicht übernommen. Etwaige leistungs- /produktspezifische Vereinbarungen gelten vorrangig.

Der Kunde verpflichtet sich, die im Rahmen dieses Vertrages erbrachten IT-Leistungen im Einklang mit der KI-Verordnung zu nutzen.

3.3.2 Allgemeine Nutzungsbedingungen

Die Telekom stellt dem Kunden mit dem LLM-Serving-Service einen KI-Service zur Verfügung, der den Zugriff auf verschiedene LLMs zur eigenverantwortlichen Nutzung ermöglicht.

Die durch den KI-Service generierten Ergebnisse unterliegen weder der Kontrolle noch dem Einfluss der Telekom. Die Telekom ist daher, soweit gesetzlich zulässig, nicht für die durch den KI-Service generierten Ergebnisse und deren Verwendung durch den Kunden, insbesondere im Hinblick auf die Freiheit von Rechten Dritter, verantwortlich.

Durch die Nutzung des KI-Service erklärt sich der Kunde mit folgenden Bedingungen einverstanden:

- a. Der Kunde stellt bei der Nutzung der Leistung, sowie der Verwendung von generierten Ergebnissen sicher, dass er in diesem Zusammenhang aller für ihn anwendbaren

rechtlichen Vorschriften, insbesondere der Vorschriften des EU AI Act, datenschutzrechtlicher Bestimmungen (z.B. Zulässigkeitsvoraussetzungen wie Mindestalter) und sonstiger branchenspezifischen Bedingungen oder interner Vorgaben einhält.

- b. Der Einsatz von KI kann fehlerhafte, unvollständige, beleidigende oder durch Rechte Dritter geschützte Inhalte liefern. Der Kunde verpflichtet sich, eine Überwachung des KI-Einsatzes sicherzustellen und seine Nutzer zum KI-Einsatz zu informieren, insbesondere wird der Kunde
- generierte Ergebnisse für den jeweiligen Anwendungsfall auf Richtigkeit und Angemessenheit durch eine menschliche Überprüfung bewerten, bevor er die generierten Ergebnisse verwendet oder weitergibt.
 - sich nicht auf die generierten Ergebnisse verlassen oder Entscheidungen ausschließlich basierend auf den generierten Ergebnissen treffen, insbesondere, wenn er medizinischen, rechtlichen, finanziellen oder anderen professionellen Rat sucht.
 - generierte Ergebnisse, die sich auf eine Person beziehen, nicht für einen Zweck verwenden, der rechtliche oder wesentliche Auswirkungen auf diese Person haben könnte, wie z. B. das Treffen von Kredit-, Bildungs-, Beschäftigungs-, Versicherungs-, rechtlichen, medizinischen oder anderen wichtigen Entscheidungen.

3.3.3 Lizenzen, Nutzungsbedingungen und Datenschutzbestimmungen

Durch die Nutzung der jeweiligen LLMs und Embedding Modelle akzeptiert der Kunde die folgend aufgeführten Nutzungsbedingungen, einschließlich der Datenschutzbestimmungen und Lizenzbedingungen für das jeweilige Modell in ihrer jeweils aktuellen Fassung, wodurch eine Vereinbarung zwischen dem Kunden und dem jeweiligen Anbieter zustande kommt:

Modell	Plattform	Nutzungsbedingungen	Datenschutzbestimmungen
OpenAI GPT-5 OpenAI GPT-5 mini OpenAI GPT-5 nano OpenAI GPT-5 Codex OpenAI Ada Text OpenAI GPT-5.4 OpenAI GPT-5.4 mini OpenAI GPT-5.5 OpenAI GPT-Image-2 Anthropic Claude 4.5 Haiku Anthropic Claude 4.6 Sonnet Anthropic Claude 4.6 Opus Anthropic Claude 4.8 Opus OpenAI GPT-5.6 Sol OpenAI GPT-5.6 Terra OpenAI GPT-5.6 Luna Anthropic Claude Sonnet 5 Anthropic Claude Fable 5 Anthropic Claude Opus 5	Microsoft Azure	https://www.microsoft.com/licensing/terms/productoffering/MicrosoftAzure/MCA#ServiceSpecificTerms	https://www.microsoft.com/licensing/docs/view/Microsoft-Products-and-Services-Data-Protection-Addendum-DPA

Modell	Plattform	Nutzungsbedingungen	Datenschutzbestimmungen
Anthropic Claude 4.5 Haiku Anthropic Claude 4.6 Sonnet Anthropic Claude 4.6 Opus Anthropic Claude 4.8 Opus Anthropic Claude Sonnet 5 Anthropic Claude Fable 5 Anthropic Claude Opus 5 Mistral AI Mistral Medium Google Gemini 3 Flash Google Gemini 3 Pro Google Gemini 3.1 Pro Google Gemini 3.5 Flash Google Gemini 3 Pro Image	Google Cloud Platform	https://cloud.google.com/terms/services https://cloud.google.com/terms/aup	https://cloud.google.com/terms/data-processing/terms https://cloud.google.com/terms/cloud-privacy-notice
Jina AI jina-embeddings-v2-base-de OpenAI GPT-OSS-120B OpenAI Whisper Large v3 Gemma 4 31B Mistral AI Mistral Small 4 Qwen3.6 35B Qwen 3.8 27B	T-Cloud Public, Open Source	https://www.apache.org/licenses/LICENSE-2.0.html	
OpenAI Whisper Large v3 Turbo	T-Cloud Public, Open Source	https://choosealicense.com/licenses/mit/	
BAAI text-embedding-bge-m3	T-Cloud Public, Open Source	https://opensource.org/licenses/mit	
GLM 5.2 GLM 5.3 Flash	T-Cloud Public, Industrial AI Cloud, Open Source	https://opensource.org/licenses/mit	
NVIDIA Nemotron 3 Super	T-Cloud Public, Open Source	https://www.nvidia.com/en-us/agreements/enterprise-software/nvidia-open-model-license/	

3.3.4 Medical Device Regulation (MDR)

Der LLM-Serving-Service ist kein Medizinprodukt im Sinne von Art. 2 Nr.1 MDR. Der Kunde verpflichtet sich, den LLM-Serving-Service nicht als Medizinprodukt und insbesondere nicht zu folgenden Zwecken einzusetzen:

- Diagnose, Verhütung, Überwachung, Vorhersage, Prognose, Behandlung oder Linderung von Krankheiten,
- Diagnose, Überwachung, Behandlung, Linderung von oder Kompensierung von Verletzungen oder Behinderungen,
- Untersuchung, Ersatz oder Veränderung der Anatomie oder eines physiologischen oder pathologischen Vorgangs oder Zustands,
- Gewinnung von Informationen durch die In-vitro-Untersuchung von aus dem menschlichen Körper — auch aus Organ-, Blut- und Gewebespenden — stammenden Proben

3.3.5 Hochrisiko-KI-Systeme, Verbotene Anwendungsfälle

Die Telekom erbringt die vertraglichen Leistungen ausschließlich auf Grundlage der vereinbarten Zweckbestimmung. Diese schließt die Nutzung als Hochrisiko-KI-System oder jegliche verbotene Anwendung im Sinne der KI-Verordnung aus. Der Kunde sichert zu, die Leistungen der Telekom nicht als Hochrisiko-KI-System oder zu verbotenen Zwecken im Sinne der KI-Verordnung einzusetzen oder einsetzen zu lassen.

3.3.6 Haftung, Freistellung, Kündigung

Bei wiederholten oder schwerwiegenden Verstößen des Kunden gegen diese Nutzungs- und Lizenzbestimmungen ist die Telekom berechtigt, den Vertrag aus wichtigem Grund ohne Einhaltung einer Frist zu kündigen zu kündigen.

Die Telekom haftet, soweit gesetzlich zulässig, nicht für Schäden, die aus der Nichteinhaltung dieser Nutzungs- und Lizenzbestimmungen resultieren.

Zudem stellt der Kunde die Telekom diesbezüglich von allen Ansprüchen Dritter (insb. Aufsichtsbehörden) auf erstes Anfordern vollumfänglich frei. Weitergehende Ansprüche der Telekom bleiben unberührt.

3.3.7 Feedback

Der Kunde räumt der Telekom und ihren verbundenen Unternehmen ein uneingeschränktes Nutzungsrecht an dessen Feedback und Ideen zu den beschriebenen Leistungen ein.

3.4 Optionale Leistungen

Die nachfolgenden optionalen Leistungen werden bei gesonderter Beauftragung gegen zusätzliche Vergütung erbracht. Auf Anfrage beim zuständigen Telekom-Vertriebsmitarbeiter wird die Telekom dem Kunden nach erfolgreicher Prüfung ein Angebot, sowie detaillierte Beschreibungen der Leistungen zur Verfügung stellen.

3.4.1 LLMs auf dedizierter Instanz

Die Telekom stellt einzelne LLMs und Embeddings auf einer dedizierten Instanz bereit. Der Kunde hat so exklusiven Zugang zu dem jeweiligen Sprachmodell, ohne es mit anderen Kunden zu teilen.

3.4.2 Feintuning von Modellen

Der LLM-Serving-Service kann um Funktionalitäten für das Feintuning von LLMs erweitert werden. Auf Anfrage stellt die Telekom die Funktionalität samt Dokumentation zur Verfügung und unterstützt bei der Erstellung und Integration des feingetunten Modells in die Gesamtlösung.

3.4.3 Installation auf einer kundeneigenen Umgebung

Auf Anfrage prüft die Telekom die Möglichkeiten der Bereitstellung der Leistung auf einer kundeneigenen Umgebung. Ergibt die Prüfung der Telekom, dass die Umgebung des Kunden die erforderlichen Anforderungen erfüllt, stellt die Telekom die Leistungen im Rahmen einer kundenspezifischen Lösung auf dessen Umgebung bereit und übernimmt bei entsprechender Beauftragung den Betrieb der kundenspezifischen Lösung.

3.4.4 Zusätzliche LLMs und Embedding Modelle

Die Telekom stellt dem Kunden LLMs und Embedding Modelle, die nicht zu den aktuell verfügbaren LLMs und Embedding Modellen gehören, auf einer kundeneigenen oder dedizierten Instanz bereit. Die Telekom unterbreitet dem Kunden ein entsprechendes Angebot, bei Vorliegen eines positiven Prüfungsergebnisses zur technischen Machbarkeit.

3.4.5 Weitere Unterstützungsleistungen

Die Telekom unterstützt den Kunden individuell mit folgenden Dienstleistungen auf Basis von Time & Material:

- Implementierungssupport
- Beratung/Coaching
- Schulung

4 Leistungsänderungen durch Telekom

Beabsichtigt die Telekom Änderungen der rechtlichen Bedingungen dieser Leistungsbeschreibung, der Leistungen oder Preise vorzunehmen, so werden die Änderungen dem Kunden mindestens einen Monat vor ihrem Wirksamwerden in Textform (z. B. per Brief

oder E-Mail) mitgeteilt. Die Änderungen werden unter den nachfolgenden Voraussetzungen der Ziffern a) bis b) Vertragsbestandteil:

- a. Änderungen zu Gunsten des Kunden zum Zeitpunkt ihres Wirksamwerdens.
- b. Preiserhöhungen, Änderungen der rechtlichen Bedingungen und nicht lediglich unerheblichen Änderungen der Leistungen zu Ungunsten des Kunden zum Zeitpunkt ihres Wirksamwerdens. Dies gilt nicht, sofern der Kunde die Leistung ohne Einhaltung einer Kündigungsfrist zu diesem Zeitpunkt in Textform kündigt. Auf das Kündigungsrecht wird der Kunde in der Änderungsmitteilung ausdrücklich hingewiesen.

5 Mitwirkungsleistungen des Kunden

Der Kunde ist verpflichtet alle Leistungen, die zur ordnungsgemäßen Leistungserbringung durch Telekom erforderlich sind, insbesondere jedoch nachfolgende, unentgeltlich, rechtzeitig und im erforderlichen Umfang zu erbringen:

5.1 Allgemeine Mitwirkungsleistungen

- a. Der Kunde ist verpflichtet, einen qualifizierten und entscheidungsbefugten Ansprechpartner zu benennen und dessen Erreichbarkeit/Vertretung sicherzustellen.
- b. Der Kunde benennt bis zu 5 Administratoren, die ausreichend qualifiziert und berechtigt sind, Supportanfragen an die Telekom zu stellen
- c. Der Kunde erklärt sich mit dem unverschlüsselten Schriftwechsel per E-Mail einverstanden und wird stets eine aktuelle E-Mail Adresse hinterlegen. Dem Kunden ist bekannt, dass für die Leistungserbringung wesentliche Informationen, wie Zugangsdaten, Informationen zu Änderungen der Leistungen und der rechtlichen Bedingungen, sowie Rechnungen ausschließlich per Mail versendet werden.
- d. Der Kunde prüft eigenverantwortlich, ob die von ihm im Zusammenhang mit der Nutzung der Leistung an die Telekom übermittelten Daten personenbezogene Daten darstellen und die Verarbeitung dieser personenbezogenen Daten zulässig ist. Sofern der Kunde personenbezogene Daten verarbeiten lassen möchte, wird dieser eine Vereinbarung über die Verarbeitung personenbezogener Daten nach dem Muster der Telekom abschließen, welches die Telekom dem Kunden auf Anfrage zur Verfügung stellt.
- e. Der Kunde prüft eigenverantwortlich alle für ihn im Zusammenhang mit der Nutzung der Leistung relevanten und anwendbaren rechtlichen Vorschriften, Gesetze, Verordnungen und branchenspezifischen Bestimmungen und stellt deren Einhaltung sicher. Dazu zählen insbesondere auch die Einhaltung von Geheimhaltungsverpflichtungen, die z.B. aus einer beruflichen Tätigkeit herrühren, sowie die Einhaltung der Nutzungs- und Lizenzbestimmungen.
- f. Der Kunde stellt sicher, dass die Leistungen nicht missbräuchlich genutzt werden.
- g. Der Kunde stellt der Telekom alle erforderlichen Informationen zur Verfügung und stellt sicher, dass seine Angaben inhaltlich richtig und stets aktuell sind.
- h. Der Kunde ist verpflichtet Einrichtungen und Leistungen der Telekom vor unberechtigtem Zugriff, Schadsoftware und sonstigen Beeinträchtigungen durch geeignete Maßnahmen zu schützen, diese pfleglich zu behandeln und die Angaben der Hersteller zu beachten.
- i. Der Kunde ist verpflichtet Passwörter und Zugangsdaten, insbesondere von ihm generierte API-Keys, geheim zu halten, nur an berechnigte Dritte weiterzugeben, bzw. vor deren Zugriff

zu schützen und soweit erforderlich zu ändern. Der Kunde wird die Telekom unverzüglich bei Anhaltspunkten der Kenntnisnahme durch unberechtigte Dritte informieren.

j. Support

Der Kunde ist verpflichtet, die Telekom bei der Behebung einer Störung/Beeinträchtigung zu unterstützen.

Insbesondere erbringt der Kunde für seine Nutzer einen 1st Level Support (User Helpdesk) und führt in diesem Rahmen eine Selbstprüfung durch, um auszuschließen, dass die Störungsursache in seinem Verantwortungsbereich liegt. Der Kunde behebt alle Störungen in seinem Verantwortungsbereich eigenständig.

Soweit der Kunde Störungen nicht eigenständig beheben kann und diese durch die Telekom zu vertreten sind, meldet der Kunde diese Störungen dem Support der Telekom mit einer nachvollziehbaren Schilderung der Fehlersymptome und unter Angabe sonstiger relevanter Informationen.

Der Kunde ist verpflichtet Störungen, Beeinträchtigungen der Leistungen oder Beschädigungen an den Einrichtungen der Telekom unverzüglich anzuzeigen.

- k. Der Kunde ist verpflichtet, für eine ausreichende Deckung des vereinbarten Abbuchungskontos zu sorgen, sowie im Falle der Zahlung per Kreditkarte seine bei der Registrierung hinterlegten Kreditkartendaten auf dem aktuellen Stand zu halten.
- l. Für den Zugriff auf den API-Endpoint via der Python-Bibliothek „openai“ stellt der Kunde die benötigte Software bei und stellt sicher, dass diese stets aktuell ist.
- m. Der Kunde stellt sicher, dass er über die erforderlichen Nutzungsrechte (einschließlich Updates oder Upgrades) verfügt.
- n. Der Kunde stellt die Einhaltung der Bestimmungen dieser Leistungsbeschreibung, insbesondere der Mitwirkungsleistungen, sowie Nutzungs- und Lizenzbestimmungen durch seine Nutzer sicher.
- o. Der Kunde wird die Telekom unverzüglich in Textform informieren, wenn er eine Mitwirkungsleistung nicht wie vereinbart erbringen kann, oder Umstände eintreten, die der Telekom die Erbringung der Leistungen erschweren oder unmöglich machen.

5.2 Mitwirkungsleistungen bei Betrieb

- a. Der Kunde stellt sicher, dass er keine Daten, Inhalte oder sonstige Eingaben verwendet, auf dem vertragsgegenständlichen Speicherplatz speichert oder sonst zugänglich macht, die Malicious Codes oder sonstige Schadsoftware enthalten, und/oder deren Bereitstellung, Veröffentlichung, Übertragung oder Nutzung gegen geltendes Recht oder Rechte Dritter verstößt.
- b. Der Kunde stellt sicher, dass von seiner Nutzung der Leistung keine Gefährdung oder Störung Dritter oder der Einrichtungen und Leistungen der Telekom ausgeht. Im Falle einer solchen Gefährdung oder Störung (z.B. auf Grund einer DDoS Attacke) ist die Telekom ohne vorherige Benachrichtigung des Kunden berechtigt, die betroffene Leistung bis zur Beseitigung der Ursache der Gefährdung oder Störung zu deaktivieren. Die hierdurch entstehenden Ausfallzeiten bleiben bei der Berechnung der Verfügbarkeit unberücksichtigt. Die Telekom wird den Kunden informieren.
- a. Der Kunde informiert die Telekom unverzüglich über alle mutmaßlichen, die Einrichtungen und Leistungen der Telekom betreffenden, sicherheitsrelevanten Vorfälle.

6 Mindestlaufzeit/Beendigung

Die Leistung ist mit einer Frist von einem Monat zum Monatsende kündbar. Alle Kündigungen haben per E-Mail an die im Rahmen der Bereitstellung bekanntgegebene E-Mail-Adresse unter Angabe der Vertragsnummer zu erfolgen.

Mit Beendigung des LLM-Serving-Services werden alle Zugangsmöglichkeiten deaktiviert und die Daten des Kunden gelöscht.

Das Recht zur außerordentlichen Kündigung bleibt hiervon unberührt.

7 Preise, Kommerzielle Bedingungen

7.1 Verfahren der Entgeltberechnung

a) Tokenverbrauch

Die Nutzung der Modelle wird basierend auf der Anzahl der verbrauchten Tokens abgerechnet. Der Tokenverbrauch ist im LLM-Self-Service-Portal einsehbar. Die Abrechnung erfolgt je angefangener Million Input-/Output-Tokens für das jeweilige Modell.

b) Tarife

Die Telekom stellt den LLM-Serving-Service in unterschiedlichen Tarifen bereit. Diese Tarife unterscheiden sich in den folgenden Aspekten:

- Verfügbare Modelle
- Max. Input TPM (Token per Minute): Maximale Anzahl von verarbeiteten Input-Token pro Minute
- Max. Output TPM (Token per Minute): Maximale Anzahl von verarbeiteten Output-Token pro Minute
- Max. RPM (Requests per Minute): Maximale Anzahl von Anfragen pro Minute, die an das LLM gestellt werden können

Bei Tarifen mit Mindestumsatz berechnet die Telekom auch bei einer den Mindestumsatz unterschreitenden Nutzung des Kunden den jeweiligen Mindestumsatz.

Bei untermonatlicher Bereitstellung/Beendigung eines Tarifs wird der Mindestumsatz anteilig nach Kalendertagen berechnet. Tarifwechsel sind auf Anfrage einvernehmlich möglich.

Die Telekom weist darauf hin, dass es sich bei den Werten Max Input TPM, Max Output TPM, Max RPM um maximal mögliche Rate-Limits handelt. Die tatsächlich zu erwartenden Durchsätze werden darunter liegen.

c) Rechnungsstellung

Die Telekom stellt dem Kunden für den jeweils vorangegangenen Kalendermonat monatlich eine Rechnung.

d) Steuern und Abgaben

Alle Preise sind in Euro angegeben und verstehen sich zuzüglich der zum Zeitpunkt der Lieferung und Leistung geltenden Steuern und Abgaben.

7.2 Preise

Für alle über T-Cloud Public / Industrial AI Cloud gehosteten Modelle beträgt der Preis für zwischengespeicherte Input-Token (Cached Input) 15 % des jeweiligen Input-Token-Preises.

7.2.1 Tarif Essential

Der monatliche Mindestumsatz für Modelle im Tarif Essential beträgt: 1.000€.

Plattform	Modell	Modell-typ	Max. Input TPM	Max. Output TPM	Max. RPM	Preis pro Million Input-Token	Preis pro Million Output-Token
T-Cloud Public	Jina AI jina-embeddings-v2-base-de	Em-bedding	300.000	150.000	300	0,05€	0,05€
T-Cloud Public	BAAI text-embedding-bge-m3	Em-bedding	300.000	150.000	300	0,05€	0,05€
T-Cloud Public	OpenAI Whisper Large v3	STT	218		300	14,61 €	14,61 €
T-Cloud Public	OpenAI Whisper Large v3 Turbo	STT	345		300	9,21 €	9,21 €
T-Cloud Public	OpenAI GPT-OSS-120B	LLM	400.000	400.000	100	0,20€	0,65€
T-Cloud Public	Gemma 4 31B Mistral AI Mistral Small 4 Qwen3.6 35B NVIDIA Nemotron 3 Super	LLM	50.000	50.000	50	0,60€	1,20€
T-Cloud Public	Qwen 3.8 27B	LLM	50.000	50.000	50	0,50€	2,50€
T-Cloud Public / Industrial AI Cloud	GLM 5.2	LLM	400.000	400.000	100	1,50€	3,50€
T-Cloud Public / Industrial AI Cloud	GLM 5.3 Flash	LLM	400.000	400.000	100	0,20€	0,60€
Microsoft Azure	OpenAI GPT-5 Azure Sweden	LLM	3,000,000	1,500,000	30,000	1,20 €	9,55 €
Microsoft Azure	OpenAI GPT-5 mini Azure Sweden	LLM	3,000,000	1,500,000	3,000	0,24 €	1,91 €
Microsoft Azure	OpenAI GPT-5 nano Azure Sweden	LLM	45,000,000	22,500,000	45,000	0,05 €	0,39 €
Microsoft Azure	OpenAI GPT-5 Codex Azure Sweden	LLM	3,000,000	1,500,000	3,000	1,1€	8,7€
Microsoft Azure	OpenAI GPT-5.4 Azure Sweden	LLM	1.500.000	750.000	1.500	2,42€	14,49€
Microsoft Azure	OpenAI GPT-5.4 mini Azure Sweden	LLM	1.500.000	750.000	1.500	0,66€	3,95€
Microsoft Azure	OpenAI GPT-5.5 Azure Sweden	LLM	1.500.000	750.000	1.500	4,83€	28,97€
Microsoft Azure	OpenAI GPT-5.6 Sol Azure Sweden	LLM	250.000	125.000	250	4,50€	27,00€
Microsoft Azure	OpenAI GPT-5.6 Terra Azure Sweden	LLM	750.000	375.000	750	3,52€	15,82€
Microsoft Azure	OpenAI GPT-5.6 Luna Azure Sweden	LLM	750.000	375.000	750	0,20€	1,20€
Microsoft Azure	OpenAI GPT-Image-2 (Input Text, Output Image)	LLM			1	4,39€	26,33€

Plattform	Modell	Modell-typ	Max. Input TPM	Max. Output TPM	Max. RPM	Preis pro Million Input-Token	Preis pro Million Output-Token
Microsoft Azure	OpenAI GPT-Image-2 (Input Image, Output Image)	LLM			1	7,03€	26,33€
Microsoft Azure	OpenAI Ada-Text, Azure France	Em-bedding	3,000,000	1,500,000	3,000	0,11€	0,11€
Google Cloud Platform	Mistral AI Mistral Medium 3	LLM	120.000	60.000	90	0,36 €	1,80 €
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.6 Sonnet	LLM	1.200.000	600.000	1.200	2,97€	14,85€
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.5 Haiku	LLM	1.200.000	600.000	1.200	0,99€	4,95€
Google Cloud Platform & Microsoft Azure	Anthropic Claude Sonnet 5	LLM	125.000	62.500	125	2,97€	14,85€
Google Cloud Platform	Google Gemini 3 Flash	LLM	DSQ	DSQ	DSQ	0,45€	2,70€
Google Cloud Platform	Google Gemini 3 Pro <=200k Input-Tokens	LLM	DSQ	DSQ	DSQ	1,80 €	10,80 €
Google Cloud Platform	Google Gemini 3 Pro >200k Input-Tokens	LLM	DSQ	DSQ	DSQ	3,60 €	16,20 €
Google Cloud Platform	Google Gemini 3.1 Pro <=200k Input-Tokens	LLM	DSQ	DSQ	DSQ	1,80 €	10,80 €
Google Cloud Platform	Google Gemini 3.1 Pro >200k Input-Tokens	LLM	DSQ	DSQ	DSQ	3,60 €	16,20 €
Google Cloud Platform	Google Gemini 3.5 Flash	LLM	DSQ	DSQ	DSQ	1,49 €	8,91 €
Google Cloud Platform	Google Gemini 3 Pro Image	LLM	DSQ	DSQ	DSQ	1,80 €	108,00 €

7.2.2 Tarif Professional

Der monatliche Mindestumsatz für Modelle im Tarif Professional beträgt: 3.000€

Plattform	Modell	Modell-typ	Max. Input TPM	Max. Output TPM	Max. RPM	Preis pro Million Input-Token	Preis pro Million Output-Token
T-Cloud Public	Jina AI jina-embeddings-v2-base-de	Em-bedding	600.000	300.000	600	0,05€	0,05€
T-Cloud Public	BAAI text-embedding-bge-m3	Em-bedding	600.000	300.000	600	0,05€	0,05€
T-Cloud Public	OpenAI Whisper Large v3	STT	218		300	14,61 €	14,61 €
T-Cloud Public	OpenAI Whisper Large v3 Turbo	STT	345		300	9,21 €	9,21 €
T-Cloud Public	OpenAI GPT-OSS-120B	LLM	1.000.000	1.000.000	200	0,20€	0,65€

Plattform	Modell	Modell- typ	Max. Input TPM	Max. Output TPM	Max. RPM	Preis pro Million Input- Token	Preis pro Million Output- Token
T-Cloud Public	Gemma 4 31B Mistral AI Mistral Small 4 Qwen3.6 35B NVIDIA Nemotron 3 Super	LLM	100.000	100.000	100	0,60€	1,20€
T-Cloud Public	Qwen 3.8 27B	LLM	100.000	100.000	100	0,50€	2,50€
T-Cloud Public / Industrial AI Cloud	GLM 5.2	LLM	1.000.000	1.000.000	200	1,50€	3,50€
T-Cloud Public / Industrial AI Cloud	GLM 5.3 Flash	LLM	1.000.000	1.000.000	200	0,20€	0,60€
Microsoft Azure	OpenAI GPT-5 Azure Sweden	LLM	6,000,000	3,000,000	60,000	1,20 €	9,55 €
Microsoft Azure	OpenAI GPT-5 mini Azure Sweden	LLM	6,000,000	3,000,000	6,000	0,24 €	1,91 €
Microsoft Azure	OpenAI GPT-5 nano Azure Sweden	LLM	90,000,000	45,000,000	90,000	0,05 €	0,39 €
Microsoft Azure	OpenAI GPT-5 Codex Azure Sweden	LLM	6,000,000	3,000,000	6,000	1,1€	8,7€
Microsoft Azure	OpenAI GPT-5.4 Azure Sweden	LLM	3.000.000	1.500.000	3.000	2,42€	14,49€
Microsoft Azure	OpenAI GPT-5.4 mini Azure Sweden	LLM	3.000.000	1.500.000	3.000	0,66€	3,95€
Microsoft Azure	OpenAI GPT-5.5 Azure Sweden	LLM	3.000.000	1.500.000	3.000	4,83€	28,97€
Microsoft Azure	OpenAI GPT-5.6 Sol Azure Sweden	LLM	500.000	250.000	500	4,50€	27,00€
Microsoft Azure	OpenAI GPT-5.6 Terra Azure Sweden	LLM	1.500.000	750.000	1.500	3,52€	15,82€
Microsoft Azure	OpenAI GPT-5.6 Luna Azure Sweden	LLM	1.500.000	750.000	1.500	0,20€	1,20€
Microsoft Azure	OpenAI GPT-Image-2 (Input Text, Output Image)	LLM			3	4,39€	26,33€
Microsoft Azure	OpenAI GPT-Image-2 (Input Image, Output Image)	LLM			3	7,03€	26,33€
Microsoft Azure	OpenAI Ada-Text, Azure France	Em- bedding	6,000,000	3,000,000	6,000	0,11€	0,11€
Google Cloud Platform	Mistral AI Mistral Medium 3	LLM	240.000	120.000	180	0,36 €	1,80 €
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.6 Sonnet	LLM	2.400.000	1.200.000	2.400	2,97€	14,85€
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.5 Haiku	LLM	2.400.000	1.200.000	2.400	0,99€	4,95€
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.6 Opus	LLM	1.200.000	600.000	1.200	4,95€	24,75€
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.8 Opus	LLM	600.000	300.000	600	4,95€	24,75€

Plattform	Modell	Modell-typ	Max. Input TPM	Max. Output TPM	Max. RPM	Preis pro Million Input-Token	Preis pro Million Output-Token
Google Cloud Platform & Microsoft Azure	Anthropic Claude Opus 5	LLM	250.000	125.000	250	4,95€	24,75€
Google Cloud Platform & Microsoft Azure	Anthropic Claude Sonnet 5	LLM	250.000	125.000	250	2,97€	14,85€
Google Cloud Platform & Microsoft Azure	Anthropic Claude Fable 5	LLM	250.000	125.000	250	9,90€	49,50€
Google Cloud Platform	Google Gemini 3 Flash	LLM	DSQ	DSQ	DSQ	0,45€	2,70€
Google Cloud Platform	Google Gemini 3 Pro <=200k Input-Tokens	LLM	DSQ	DSQ	DSQ	1,80 €	10,80 €
Google Cloud Platform	Google Gemini 3 Pro >200k Input-Tokens	LLM	DSQ	DSQ	DSQ	3,60 €	16,20 €
Google Cloud Platform	Google Gemini 3.1 Pro <=200k Input-Tokens	LLM	DSQ	DSQ	DSQ	1,80 €	10,80 €
Google Cloud Platform	Google Gemini 3.1 Pro >200k Input-Tokens	LLM	DSQ	DSQ	DSQ	3,60 €	16,20 €
Google Cloud Platform	Google Gemini 3.5 Flash	LLM	DSQ	DSQ	DSQ	1,49 €	8,91 €
Google Cloud Platform	Google Gemini 3 Pro Image	LLM	DSQ	DSQ	DSQ	1,80 €	108,00 €

7.2.3 Tarif Agentic

Der monatliche Mindestumsatz für Modelle im Tarif Agentic beträgt: 5.000€

Plattform	Modell	Modell-typ	Max. Input TPM	Max. Output TPM	Max. RPM	Preis pro Million Input-Token	Preis pro Million Output-Token
T-Cloud Public	Jina AI jina-embeddings-v2-base-de	Em-bedding	2.000.000	1.000.000	1000	0,05€	0,05€
T-Cloud Public	BAAI text-embedding-bge-m3	Em-bedding	2.000.000	1.000.000	1000	0,05€	0,05€
T-Cloud Public	OpenAI Whisper Large v3	STT	218		300	14,61 €	14,61 €
T-Cloud Public	OpenAI Whisper Large v3 Turbo	STT	345		300	9,21 €	9,21 €
T-Cloud Public	OpenAI GPT-OSS-120B	LLM	2.000.000	2.000.000	300	0,20€	0,65€
T-Cloud Public	Gemma 4 31B Mistral AI Mistral Small 4 Qwen3.6 35B NVIDIA Nemotron 3 Super	LLM	300.000	300.000	150	0,60€	1,20€
T-Cloud Public	Qwen 3.8 27B	LLM	300.000	300.000	150	0,50€	2,50€

Plattform	Modell	Modell- typ	Max. Input TPM	Max. Output TPM	Max. RPM	Preis pro Million Input- Token	Preis pro Million Output- Token
T-Cloud Public / Industrial AI Cloud	GLM 5.2	LLM	2.000.000	2.000.000	300	1,50€	3,50€
T-Cloud Public / Industrial AI Cloud	GLM 5.3 Flash	LLM	2.000.000	2.000.000	300	0,20€	0,60€
Microsoft Azure	OpenAI GPT-5 Azure Sweden	LLM	10,000,000	5,000,000	100,000	1,20 €	9,55 €
Microsoft Azure	OpenAI GPT-5 mini Azure Sweden	LLM	10,000,000	5,000,000	10,000	0,24 €	1,91 €
Microsoft Azure	OpenAI GPT-5 nano Azure Sweden	LLM	150,000,000	75,000,000	150,000	0,05 €	0,39 €
Microsoft Azure	OpenAI GPT-5 Codex Azure Sweden	LLM	10,000,000	5,000,000	10,000	1,1€	8,7€
Microsoft Azure	OpenAI GPT-5.4 Azure Sweden	LLM	5.000.000	2.500.000	5.000	2,42€	14,49€
Microsoft Azure	OpenAI GPT-5.4 mini Azure Sweden	LLM	5.000.000	2.500.000	5.000	0,66€	3,95€
Microsoft Azure	OpenAI GPT-5.5 Azure Sweden	LLM	5.000.000	2.500.000	5.000	4,83€	28,97€
Microsoft Azure	OpenAI GPT-5.6 Sol Azure Sweden	LLM	1.000.000	500.000	1000	4,50€	27,00€
Microsoft Azure	OpenAI GPT-5.6 Terra Azure Sweden	LLM	2.500.000	1.250.000	2.500	3,52€	15,82€
Microsoft Azure	OpenAI GPT-5.6 Luna Azure Sweden	LLM	2.500.000	1.250.000	2.500	0,20€	1,20€
Microsoft Azure	OpenAI GPT-Image-2 (Input Text, Output Image)	LLM			5	4,39€	26,33€
Microsoft Azure	OpenAI GPT-Image-2 (Input Image, Output Image)	LLM			5	7,03€	26,33€
Microsoft Azure	OpenAI Ada-Text, Azure France	Em- bedding	10,000,000	5,000,000	10,000	0,11€	0,11€
Google Cloud Platform	Mistral AI Mistral Medium 3	LLM	400.000	200.000	300	0,36 €	1,80 €
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.6 Sonnet	LLM	4.000.000	2.000.000	4.000	2,97€	14,85€
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.5 Haiku	LLM	4.000.000	2.000.000	4.000	0,99€	4,95€
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.6 Opus	LLM	2.000.000	1.000.000	2.000	4,95€	24,75€
Google Cloud Platform or Microsoft Azure	Anthropic Claude 4.8 Opus	LLM	1.000.000	500.000	1.000	4,95€	24,75€
Google Cloud Platform & Microsoft Azure	Anthropic Claude Opus 5	LLM	500.000	250.000	500	4,95€	24,75€
Google Cloud Platform & Microsoft Azure	Anthropic Claude Sonnet 5	LLM	500.000	250.000	500	2,97€	14,85€

Plattform	Modell	Modell- typ	Max. Input TPM	Max. Output TPM	Max. RPM	Preis pro Million Input- Token	Preis pro Million Output- Token
Google Cloud Platform & Microsoft Azure	Anthropic Claude Fable 5	LLM	500.000	250.000	500	9,90€	49,50€
Google Cloud Platform	Google Gemini 3 Flash	LLM	DSQ	DSQ	DSQ	0,45€	2,70€
Google Cloud Platform	Google Gemini 3 Pro <=200k Input-Tokens	LLM	DSQ	DSQ	DSQ	1,80 €	10,80 €
Google Cloud Platform	Google Gemini 3 Pro >200k Input-Tokens	LLM	DSQ	DSQ	DSQ	3,60 €	16,20 €
Google Cloud Platform	Google Gemini 3.1 Pro <=200k Input-Tokens	LLM	DSQ	DSQ	DSQ	1,80 €	10,80 €
Google Cloud Platform	Google Gemini 3.1 Pro >200k Input-Tokens	LLM	DSQ	DSQ	DSQ	3,60 €	16,20 €
Google Cloud Platform	Google Gemini 3.5 Flash	LLM	DSQ	DSQ	DSQ	1,49 €	8,91 €
Google Cloud Platform	Google Gemini 3 Pro Image	LLM	DSQ	DSQ	DSQ	1,80 €	108,00 €

7.2.4 Preise für optionale Dienstleistungen

Der Tagessatz für optionale Dienstleistungen wie Implementierungssupport, Beratung und Coaching beträgt 1.144,45 €.

Die Leistungen werden remote erbracht. Die Abrechnung der Unterstützungsleistungen erfolgt monatlich anhand eines vom Auftraggeber unterzeichneten Leistungsnachweises auf Basis von Time&Material.

8 Glossar/ Abkürzungsverzeichnis

Abkürzung	Erklärung
API-Key	Ein API-Key ist ein einzigartiger Authentifizierungsschlüssel, der den Zugriff auf eine Programmierschnittstelle (API) ermöglicht, indem er die aufrufende Anwendung identifiziert, authentifiziert und autorisiert.
ASR	Automatic Speech Recognition, Automatische Spracherkennung
Betreute Betriebszeit	Ist die Zeit von Montag bis Freitag jeweils von 9:00 Uhr bis 17.00 Uhr MEZ/MESZ, ausgenommen an bundeseinheitlichen Feiertagen in Deutschland
DSQ	Dynamic Shared Quota
LLM	Large Language Model
Modelle	Modelle umfassen in diesem Dokument sowohl Large Language Modelle als auch Embedding Modelle
PaaS	Platform as a Service
SaaS	Software as a Service

Abkürzung	Erklärung
Token	Token umfassen Input- als auch Output-Token, sofern nicht differenziert wird. Token sind Textsequenzen, z. B. Sätze, Wörter oder Zeichen, die ein LLM verarbeiten kann. Die Größe eines Tokens kann sich je nach LLM unterscheiden.
TPM	Die Anzahl der maximal verarbeitbaren Tokens pro Minute
RPM	Die Anzahl der maximal verarbeitbaren Requests pro Minute